

---

# DIP Final Project: Depth Image Inpainting

---

**Li-Wei Fu**

r10942078

Graduate Institute of Communication Engineering  
National Taiwan University  
r10942078@ntu.edu.tw

**Po-Yen Tseng**

r09521504

Graduate Institute of Civil Engineering  
National Taiwan University  
r09521504@ntu.edu.tw

**Yu-Kai Ling**

r09921054

Graduate Institute of Electrical Engineering  
National Taiwan University  
r09921054@ntu.edu.tw


**Wei-Min Chu**

r10546017


Graduate Institute of Industrial Engineering  
National Taiwan University  
r10546017@ntu.edu.tw

## 1 Introduction

Image inpainting?對於電腦視覺與影像處理來說是一個非常重要的研究領域，我們的主題focus在depth image inpainting，深度照相機拍攝出來的圖片都會有一些缺失的pixels，原因通常是拍到有反光還有透明的物體，或是距離深度已超出相機能偵測到的距離上限，此時相機就無法得到深度資訊。



(a) Before inpainting



(b) After inpainting

Figure 1: Example of depth image inpainting

在本次作業我們研究了幾篇使用傳統image processing方法的論文，方法都是把depth image inpainting轉換成一個Matrix Completion的問題，基於low rank、low gradients等統計學上的假設，設計一些目標函數和constrain，使用ADMM等演算法來解這些convex optimization problems。

我們主要參考Depth Image Inpainting: Improving Low Rank Matrix Completion with Low Gradient Regularization?這篇paper的方式，花了很多時間用python重現論文的貢獻LRL0<sup>ψ</sup>，同時也使用python重現了LR?、LRTV?、LRL0?這三篇paper的方法，驗證論文的結果，並且發現這些

方法對於太大的hole無法完全的填補。因此，我們嘗試運用本堂課程在morphology章節所學到的知識，加上histogram analysis，來將較大的洞做填補，進一步提升LRL0<sup>ψ</sup>的填補效果，得到一個完全沒有缺失值、最好的結果。

我們提出的填補方法簡單、很適合套用在中型大小的hole，且運算速度極快，結合前述paper的傳統方法可以達到real time，這是目前deep learning method也無法達到的。我們所有的實作都整理在GitHub(<https://github.com/kai860115/DIP-FinalProject>) 上，如果有需要的話可以參考。

## 2 Methodology & Implementation Details

### 2.1 Paper survey

目前在Depth image inpainting領域效果最好的model是Deep Depth Completion of a Single RGB-D Image ?的方法，這篇論文被引用多次，且方法好懂，利用一張圖片的表面法向量與遮擋邊界來作為input的feature，使用深度學習的模型來填補一張圖片的深度資訊，然而因為此方法較為耗時、需要大量的GPU運算資源訓練深度學習的model來進行預測，而且與本堂課程較無關係，因此我們捨棄了此篇論文的作法。

接著我們打算使用Fast Generation of High Fidelity RGB-D Images Deep-Learning with Adaptive Convolution ?這篇論文的作法，速度為前一篇文章的10倍以上，在深度學習網路的Convolution 層前加入了傳統image processing 的作法，並架設refinement network來進一步的微調，然而因為此篇paper的pretrained model 與原paper所提供的有所不同，在reproduce過程有困難，我們最後沒有使用此篇paper。




Figure 2: Refinement Network

在paper survey的過程中，我們發現很多傳統的方法會把depth image inpainting轉換成一個Matrix Completion的問題，圖片上的缺失值可以運用matrix completion algorithms來做到image inpainting的效果，且在這幾篇論文中我們發現深度的圖片通常都具有較低

的gradients，gradients 在部份地方會有vanish的現象，跟它的深度也許有相對應的關係，我們最後便往Matrix Completion跟low gradients的關鍵字做查找，並使用Depth Image Inpainting: Improving Low Rank Matrix Completion with Low Gradient Regularization?這篇paper作為我們final project主要實作的paper。

## 2.2 Background

此篇論文的核心概念便是用到Low rank的假設作為基礎，我們可以把圖片當成是一個Matrix，而圖片的hole(黑色的部分)為需要填補的缺失值，只要rank遠小於matrix的長寬 $m$ 跟 $n$ ，那缺失的entries就有可能可以被recover回來。

而這篇paper具體的填補方法，便是採用Low-rank low gradient approach，此方法為Low gradient regularization加上Low-rank assumption並進行微調，作者將這個方法取名為LRL0 <sup>$\psi$</sup> ，在介紹此方法之前，先來講解此篇paper的另外兩個比較的方法，Low rank total variation (LRTV) ?與Low rank L0 gradient (LRL0) ?。

### 2.2.1 The low rank total variation (LRTV)

一般的Matrix Completion algorithms在針對low rank的image recovery上會有一個重要的限制，因為當hole過大時，有時會發生整個row或是整個column都是缺失值的情形，在演算法上便無法填補這些缺失值，而Low-rank and total variation regularization 便是為了解決這樣的問題，total variation是將整個圖片進行梯度上的整合，並利用一個函數來對每個pixel上的梯度進行正規化與積分計算，再利用正規化的值進行填補，並設立一個cost function，變成一個最佳化問題，最後利用Alternating Direction Method of Multipliers (ADMM)演算法來進行求解。

### 2.2.2 The low rank L0 gradient (LRL0)

而利用total variation的這個方法雖然可以用來鬆弛L0的gradient，但total variation的這個方法同時也使得gradient較大的地方影響變小，會讓原來圖片的邊緣和邊界受到影響，gradient影響較不明顯，因此LRL0的作法便是採用L0的gradient作為依據，去計算一張圖片gradient為0的部分，看深度的變化幅度，並進行L0 gradient的正規化後，放入最佳化的式子中，設置一個L0 gradient的minimization problem來進行求解。

### 2.2.3 The Low rank low gradient approach (LRL0 <sup>$\psi$</sup> )

而此篇paper的做法便是將The low rank L0 gradient (LRL0)? 進行改良，使用一種低梯度正規化的方式，減少對gradient為1的影響，同時在非零的gradient上面進行懲罰，來讓深度有逐漸的變化，並將low gradient正規化跟low rank的正規化進行結合，來成為depth圖繪製的方式，並將最後結果與上述兩個方法進行比較。

### 2.2.4 Peak signal-to-noise ratio (PSNR)

而PSNR是LRL0<sup>ψ</sup>這篇論文的主要衡量指標，PSNR是一個比率，用於表示一個信號的最大功率和影響它的破壞性噪點的功率，即為一個影像修復後和原來修復前的影像比質量的好壞，PSNR越高，代表圖片修復後的效果越好，而MSE代表真實的圖像和含有噪點的圖像的所有像素差的平方再取平均值，MSE與PSNR的公式如下：

$$MSE = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W (X(i, j) - Y(i, j))^2 \quad (1)$$

$$PSNR = 10 \log_{10} \frac{(2^n - 1)^2}{MSE} \quad (2)$$

### 2.3 Dataset

Dataset 的部份我們是依據論文使用Middlebury Stereo Dataset，將原始的圖片加入雜訊損壞後，作為修復的目標，如Figure 3所示。




Figure 3: Example of the dataset

### 2.4 Reproduce result

我們用python重現了此篇paper的LRL0<sup>ψ</sup>方法，結果如Figure 4 所示。




Figure 4: The comparison of our implement and the paper

### 3 Our Improvement

如Figure 4 所示，我們發現 $LRL0^\psi$  對於修補破洞有著很好的效果，PSNR 也相當高，但是在對於破洞較大的地方，修補效果不是很理想，於是我們想針對這個部分進行補強。我們使用了上課所提到的方式，先使用影像二值化的方式來找出hole的位置(Figure 5b)，接著將hole做不同次數的dilation (Figure 5c)，然後用做完dilation的圖片和原始圖片相減，即可得到原本hole 周圍的pixels (Figure 5d)，我們將hole 做分群(Figure 5e 與Figure 5f)，分析每個hole 周圍的pixels 值，利用histogram 統計(Figure 6)，將出現機率乘以深度算出期望值填入原本的hole 中，就會得到結果如Figure 7。

因為深度圖片具有low gradient 的特性，pixel value 的變化在小範圍內不會很劇烈，所以在Figure 6 中我們可以看到hole 的邊界上的pixel value 都集中在某幾個值上，也因為這個特性，我們使用hole 邊界的pixels 來估計缺失值效果很好。經過實驗，我們的這個方法在直徑15 pixel 以內的破洞填補效果最好，愈大的洞因為橫跨不同深度的可能性愈高，而修補效果下降。

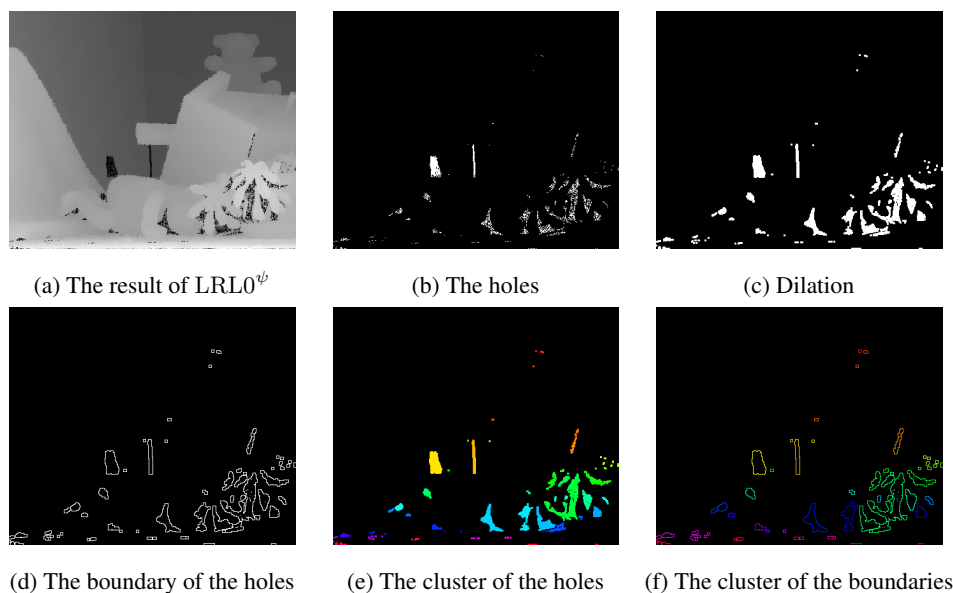


Figure 5: Some details of our improvement




Figure 6: The boundary histogram analysis




Figure 7: The result of our improvement

## 4 Sensitivity Analysis

我們針對我們提出的修補方法進行了敏感度分析，希望找出適合的參數來使我們的方法有最好的效果。首先是dilation會使用到的kernel shape比較，我們分別使用正方形、菱形、十字形的kernel在同一張圖片進行測試，kernel示意圖如Figure 8 所示。




Figure 8: Different kernels we have tested

可以從Figure 9 的結果觀察到，正方形選到的顏色會比較不連續，我們認為是因為用正方形的kernel 抓到的周圍pixels 距離hole 的距離並不完全相等，kernel 的角落會抓到距離hole 比較遠的pixels，導致在分析要填入什麼值進hole 時，會被距離較遠的pixels 誤導。在各種結果中，菱形與十字形kernel 的修補效果最好，因此之後的實驗統一使用十字形的kernel。




Figure 9: The result from different kernels

接著我們比較了不同dilation 次數的影響，結果如Figure 10。我們分別做了1、5、9次的dilation，除了運算的時間增加以外，從結果來看幾乎看不出差異，因此之後的實驗統一使用1次dilation。




Figure 10: The result of dilation tests

最後我們討論選值方法，首先把這些pixels 用histogram 做統計，第一種取值方法是用每個pixel 的機率乘上pixel value 求出期望值，用期望值當成是填補的數值；另一種是直接找出機率最高的pixel value 當成是填補的數值，比較的結果如Figure 11。由結果可以發現，直接選用機率最高的pixel value 來填補的效果不甚理想，可以看到圖中白色架子會直接延伸到後方的平台上。反之，用期望值來填補的效果非常好，因此我們最後選用期望值來當成是我們填補的基準。




Figure 11: The result of different approaches of choosing repair value

## 5 Conclusion

我們花了很多時間利用python在重現四篇paper的方法(LR、LRTV、LRL0、LRL0<sup>ψ</sup>)，跟paper結果進行比較，並理解了許多的專有名詞以及原理。並且發現使用這些方法的不足之處，所以我們利用了在本堂課程所學，利用dilation與histogram統計的方式優化paper所使用的方法，讓最後呈現的image inpainting不會有任何的缺失值，解決了LRL0<sup>ψ</sup>在遇到比較大的hole會比較劣勢的問題，而且運算速度極快，平均一張圖僅需要400ms的處理時間。雖然我們最終實作方法的PSNR結果沒有像paper所提到的那麼好，但是在視覺上的呈現結果卻比paper好了許多，在image inpainting上達到了非常完美的結果。

## References

- P. M. Patil and B. H. Deokate, "Image mapping and object removal in image inpainting using wavelet transform," in *2015 International Conference on Information Processing (ICIP)*, pp. 114–118, 2015.
- H. Xue, S. Zhang, and D. Cai, "Depth image inpainting: Improving low rank matrix completion with low gradient regularization," *IEEE Transactions on Image Processing*, vol. 26, no. 9, pp. 4311–4320, 2017.
- R. Fan, Y. Lu, and S. Wu, "Image inpainting based on low-rank alm algorithm," in *2019 14th IEEE Conference on Industrial Electronics and Applications (ICIEA)*, pp. 2373–2378, 2019.
- F. Shi, J. Cheng, L. Wang, P.-T. Yap, and D. Shen, "Lrtv: Mr image super-resolution with low-rank and total variation regularizations," *IEEE Transactions on Medical Imaging*, vol. 34, no. 12, pp. 2459–2466, 2015.
- M. Wang, Q. Wang, and J. Chanussot, "L<sup>0</sup> gradient regularized low-rank tensor model for hyperspectral image denoising," in *2019 10th Workshop on Hyperspectral Imaging and Signal Processing: Evolution in Remote Sensing (WHISPERS)*, pp. 1–6, 2019.

- Y. Zhang and T. Funkhouser, "Deep depth completion of a single rgb-d image," in *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 175–185, 2018.
- C. Xian, D. Zhang, C. Dai, and C. C. L. Wang, "Fast generation of high-fidelity rgb-d images by deep learning with adaptive convolution," *IEEE Transactions on Automation Science and Engineering*, vol. 18, no. 3, pp. 1328–1340, 2021.
- K. Joshi, R. Yadav, and S. Allwadhi, "Psnr and mse based investigation of lsb," in *2016 International Conference on Computational Techniques in Information and Communication Technologies (ICCTICT)*, pp. 280–285, 2016.